

截至 2026 年 8 月，LLM 后训练里 “RL + 蒸馏” 的前沿已经不再是简单的

$$L = L_{\text{RL}} + \lambda L_{\text{KD}},$$

而是逐渐形成一种更统一的范式：

RL 决定 “什么行为值得强化”，蒸馏决定 “应该把信用精确分配到哪些 token、哪些轨迹和哪些能力上”。目前最重要的进展可以分成 7 条路线。

## 一、为什么需要把 RL 和蒸馏结合？

标准 RLVR，例如 GRPO，使用：

$$A_i = \frac{r_i - \bar{r}}{\sigma_r},$$

再把同一个序列优势广播给所有 token：

$$L_{\text{RL}} = - \sum_t A_i \log \pi_{\theta}(y_{i,t} \mid x, y_{i,<t}).$$

它存在几个问题：

1. 只有最终 0/1 奖励，信用分配粗糙；
2. 一个回答中所有 token 获得相同优势；
3. 如果一个 prompt 的所有 rollout 都失败：

$$r_1 = r_2 = \dots = r_G = 0,$$

那么：

$$A_1 = \dots = A_G = 0,$$

模型完全学不到东西，这类题被称为 cliff prompts；4. RL 擅长探索，但很难凭空学到策略中不存在的新知识；5. 多领域连续 RL 容易遗忘已有能力。蒸馏恰好可以提供：

- 稠密、逐 token 的 teacher distribution；

- 失败原因或 privileged information;
- 外部教师的新知识;
- 多个领域教师的能力整合。但纯蒸馏又会限制学生:
- 只能逼近教师;
- 教师错误也会被复制;
- 学生自己的正确新路径可能被教师覆盖;
- 教师和学生分布差异过大时指导会失效。因此前沿方向正在从 “RL 或蒸馏” 转向 “奖励选择 + 教师指导”。

## 二、主线一：On-Policy Distillation 与 RL 的统一

标准 On-Policy Distillation (OPD) 流程是:

1. 学生自己 rollout:

$$y \sim \pi_S(\cdot | x);$$

2. 教师在学生实际访问的状态上给出分布:

$$\pi_T(\cdot | x, y_{<t});$$

3. 学生匹配教师:

$$L_{\text{OPD}} = \mathbb{E}_{y \sim \pi_S} \sum_t D_{\text{KL}}(\pi_T(\cdot | s_t) \| \pi_S(\cdot | s_t)).$$

与离线蒸馏的区别在于训练状态来自学生，而不是教师或固定数据集，因此显著减轻 exposure bias。

### G-OPD / ExOPD: OPD 本质上是特殊的 KL 约束 RL

#### Learning beyond Teacher: Generalized On-Policy Distillation with Reward

**Extrapolation** 给出了非常关键的统一解释: OPD 可以看成一种 dense KL-constrained RL。可以写成:

$$\max_{\pi} \mathbb{E}_{\pi} [\alpha r_T(s, a) - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}})].$$

普通 OPD 隐含地令奖励和 KL 约束权重固定耦合。G-OPD 将二者解耦:

- reference model 可以自由选择;
- teacher-derived reward 可以单独缩放;
- 当奖励系数大于标准 OPD 时称为 ExOPD。关键结论是: 通过 reward extrapolation, 学生能够超过教师, 而不再只能逼近教师分布。因此现在更准确的观点是:

OPD 是一种特殊的稠密奖励 KL-RL

而不是简单的“另一种 SFT”。

---

## 三、主线二: 用自蒸馏解决 RL 的稀疏信用分配

---

### 1. SDPO: 从环境文本反馈中自蒸馏

---

Reinforcement Learning via Self-Distillation 提出 SDPO。对于学生生成的答案  $y$ , 环境除了标量奖励, 还可能提供:

- 编译错误;
- runtime error;
- judge feedback;
- 工具输出;
- 科学实验反馈。SDPO 使用同一个模型扮演两个角色:

$$\begin{aligned}\pi_S &= \pi_\theta(y \mid x), \\ \pi_T^f &= \pi_\theta(y \mid x, f),\end{aligned}$$

其中  $f$  是环境反馈。带反馈的模型相当于“看完错题解析后的自己”。再把反馈条件分布蒸馏回普通策略:

$$L_{\text{SDPO}} = \sum_t D(\pi_\theta(\cdot \mid x, f, y_{<t}) \parallel \pi_\theta(\cdot \mid x, y_{<t})).$$

它不需要:

- 外部强教师;
- 独立 reward model;

- 人工过程标注。论文报告在一些实验中，SDPO 训练 1 小时可接近 GRPO 训练约 5 小时的效果。[项目页](#) SDPO 的本质是：

Sparse outcome reward + rich feedback → dense token supervision

---

## 2. Self-Distilled RLVR：把蒸馏信号嵌入 GRPO

---

**Self-Distilled RLVR** 更直接地研究怎样在 RLVR 内使用 privileged self-teacher。对同一个模型：

- 学生看普通 prompt；
- 教师额外看到正确答案、提示或验证反馈；
- 二者在相同 rollout 状态上计算 distribution gap；
- 该 gap 被用来改进 token 级信用分配。与 SDPO 的区别是：
- SDPO 主要从环境产生的 rich feedback 蒸馏；
- Self-Distilled RLVR 更直接围绕 RLVR rollout 和 privileged information 构造 token 信号。但它暴露出一个后来被大量研究的问题：

教师和学生分布的差异不一定代表“知识差异”，也可能只是风格差异或答案泄漏。这直接催生了后面的 RLCSD、RLRT 等工作。

---

## 四、主线三：只在 RL 完全学不到的 cliff prompts 上蒸馏

---

### HDPO：RL 成功时做 RL，全失败时才蒸馏

---

**HDPO: Hybrid Distillation Policy Optimization via Privileged Self-Distillation** 是目前最清晰的选择性混合框架之一。对每个 prompt 生成  $G$  个 rollout。如果至少有成功和失败：

$$0 < \sum_{i=1}^G r_i < G,$$

则使用普通 RL，因为组内有方差：

$$L(x) = L_{\text{RL}}(x).$$

如果所有 rollout 都失败：

$$\sum_{i=1}^G r_i = 0,$$

则判定为 cliff prompt。此时：

1. 给同一模型提供 ground truth 或 privileged hint;
2. 生成 privileged rollout;
3. 过滤出正确答案;
4. 将正确 privileged distribution 蒸馏给普通策略：

$$L(x) = L_{\text{distill}}(x).$$

整体可以写成：

$$L = \mathbb{E}_x[\mathbf{1}[x \notin \mathcal{C}]L_{\text{RL}} + \lambda\mathbf{1}[x \in \mathcal{C}]L_{\text{distill}}].$$

其中  $\mathcal{C}$  是全失败 prompt 集合。这是一个很重要的设计变化：

不在所有样本上无条件蒸馏，只用蒸馏填补 RL 的零梯度区域。它既保留 RL 的自主探索，又帮助模型跨过当前能力边界。

## 五、主线四：不是模仿教师，而是用教师重分配 RL 梯度

### Distilled RL: 2026 年 7 月较新的直接融合方法

[Distilled Reinforcement Learning for LLM Post-training](#) 是当前很值得关注的工作。它指出两种传统方法都有问题：

- RL：序列级奖励太粗；
- OPD：无条件匹配教师 logits，教师差异大时尤其危险。Distilled RL 不直接最小化：

$$D_{\text{KL}}(\pi_T \parallel \pi_S),$$

而是把教师信息放进 policy gradient 权重中。直观上，某个学生 token 如果同时满足：

- 来自值得强化的 rollout；
- 教师相对学生更支持这个 token；那么其梯度权重更大。其关键权重使用 teacher-to-student ratio 的反向重要性思想：

$$\rho_t^{T/S} = \frac{\pi_T(y_t | s_t)}{\pi_S(y_t | s_t)},$$

再经过 clipping，避免教师和学生差异过大造成梯度爆炸。论文进一步加入：

1. Reverse importance sampling with clipping：利用教师/学生概率比进行细粒度梯度重加权；
2. Negative sample reset：防止负奖励样本上的教师权重产生错误方向；
3. Sequence-level geometric normalization：避免长序列中概率比连乘导致尺度失控。可以粗略理解为：

$$L_{\text{DistilledRL}} \approx - \sum_t A(y) \text{clip}(\rho_t^{T/S}) \log \pi_S(y_t | s_t).$$

和 OPD 的根本区别是：

- OPD：不管 rollout 最终是否好，都倾向于匹配教师；
- Distilled RL：奖励决定方向，教师决定 token 级权重；
- OPD 是 imitation-first；
- Distilled RL 是 reward-first。论文报告它同模型族与跨模型族蒸馏中都超过标准 RL 和 OPD，并同时改善 pass@1、pass@k。代码 这是目前 “RL 与蒸馏真正融合进同一梯度估计器” 的代表工作。

---

## 六、主线五：修复自蒸馏的错误信号

---

### 1. RLCSD：用正确提示和错误提示作对比

---

[RLCSD: Reinforcement Learning with Contrastive On-Policy Self-Distillation](#) 发

现，privileged teacher 和 student 的分布差异大量集中在风格 token 上。例如教师看到答案后可能：

- 输出更短；

- 少做探索;
- 使用更直接的措辞;
- 提前停止推理。 因此:

$$\pi(\cdot \mid x, h_{\text{correct}}) - \pi(\cdot \mid x)$$

不全是知识信号，还包含“只要给 hint 就会出现”的风格漂移。RLCSD 同时构造:

- 正确 hint teacher:

$$\pi^+ = \pi(\cdot \mid x, h^+);$$

- 错误 hint teacher:

$$\pi^- = \pi(\cdot \mid x, h^-).$$

使用对比差异:

$$g_t = [\log \pi^+(y_t) - \log \pi_S(y_t)] - [\log \pi^-(y_t) - \log \pi_S(y_t)],$$

等价地突出:

$$g_t \approx \log \pi^+(y_t) - \log \pi^-(y_t).$$

正确、错误 hint 共同造成的格式变化会相互抵消，剩下的更可能是真正与正确推理有关的 token。RLCSD 再把这个信号用于调制 GRPO advantage，而不是完全替代 outcome reward。 [代码](#)

## 2. RLRT: 学生正确且与教师不同时，不应压制学生

[Rebellious Student: Reversing Teacher Signals for Reasoning Exploration with Self-Distilled RLVR](#) 提出一个很有意思的反转观点。如果学生 rollout 是错误的，教师与学生的差异可以作为纠错信号。但如果学生已经正确，而且走了一条教师没有预期到的路径，这种差异实际上代表:

valuable student exploration.

传统自蒸馏会强行把学生拉回教师:

$$\pi_S \rightarrow \pi_T,$$

从而抹掉学生自主发现的新策略。RLRT 在正确 rollout 上反向读取 teacher disagreement, 强化 “学生正确、但教师不支持” 的 token:

$$r_t^{\text{exploration}} \propto \log \pi_S(y_t) - \log \pi_T(y_t).$$

因此教师信号具有两种用途:

| 学生结果 | 教师不同意意味着  | 操作     |
|------|-----------|--------|
| 学生错误 | 可能是纠错信息   | 向教师靠近  |
| 学生正确 | 可能是学生的新发现 | 强化学生差异 |

这代表前沿方向已经从 “教师永远正确” 转向 “根据 outcome 解释教师—学生差异”。

## 七、主线六：多教师 RL 能力整合

### MOPD: 先分别 RL, 再通过 OPD 合并能力

**MOPD: Multi-Teacher On-Policy Distillation for Capability Integration** 解决多领域后训练的能力冲突问题。传统 Mix-RL 是把所有领域放在一起训练:

$$D = D_{\text{math}} \cup D_{\text{code}} \cup D_{\text{tool}} \cup D_{\text{chat}}.$$

问题包括:

- 不同领域 reward 尺度不同;
- rollout 长度和训练速度不同;
- 梯度互相干扰;
- 后训练领域可能覆盖先前能力。MOPD 采用:

#### 阶段 1: 并行训练领域教师

$$\pi_T^{\text{math}} = RL(\pi_0, D_{\text{math}}),$$

$$\pi_T^{\text{code}} = RL(\pi_0, D_{\text{code}}),$$

$$\pi_T^{\text{tool}} = RL(\pi_0, D_{\text{tool}}).$$

## 阶段 2：学生在自身分布上 rollout

$$y \sim \pi_S(\cdot | x).$$

## 阶段 3：根据领域选择对应教师

$$L = \mathbb{E}_{x \sim D_k, y \sim \pi_S} D_{\text{KL}} \left( \pi_T^{(k)}(\cdot | s_t) \| \pi_S(\cdot | s_t) \right).$$

它的工程意义非常大：

- 各领域团队可以并行做 RL；
- 最后统一蒸馏回一个模型；
- 避免一次大规模多领域 RL 的耦合；
- 可以恢复 RL 后遗忘的通用能力。论文在 Qwen3-30B-A3B 上显示，它优于 Mix-RL、Cascade RL、Off-policy finetuning 和参数合并，并已用于 MiMo-V2-Flash 的实际后训练。不过最新研究也发现 MOPD 有几个问题：
- 不同教师可能在同一 prompt 上相互抵消；
- top-k logits 可能漏掉“调用工具还是直接回答”的关键决策；
- aggregate KL 很低不代表关键行为边界正确；
- prompt 分布必须覆盖各教师的专业区域。因此后续已经出现 Counteraction-Aware MOPD、行为边界校准等工作。

## 八、主线七：多轮 Agent 中的 RL + 蒸馏 + 课程学习

这和你上一问直接相关。

### TCOD：逐渐增加蒸馏轨迹深度

#### TCOD: Exploring Temporal Curriculum in On-Policy Distillation for Multi-turn

Autonomous Agents 将课程学习加入多轮 OPD。普通多轮 OPD 从一开始就在整条学生轨迹上蒸馏：

$$s_1 \rightarrow s_2 \rightarrow \dots \rightarrow s_H.$$

早期学生错误会改变后续环境状态，使学生轨迹逐渐偏离教师熟悉的状态，teacher-student KL 随 turn 快速扩大。TCOD 提出两个方向。

## TCOD-F2B: Forward-to-Backward

从短轨迹开始，逐渐增加最大交互轮数：

$$H_1 < H_2 < \dots < H_K.$$

即：

```
先蒸馏前 2 轮
→ 再蒸馏前 4 轮
→ 再蒸馏前 8 轮
→ 最后训练完整轨迹
```

## TCOD-B2F: Backward-to-Forward

先由教师执行成功轨迹的前缀，把环境放到接近目标的中间状态，再让学生完成后半段：

```
教师完成前 8 步 → 学生完成最后 2 步
教师完成前 6 步 → 学生完成最后 4 步
.....
最终学生从头完成
```

这类似 reverse curriculum learning，能避免早期错误使学生永远到不了后段状态。实验覆盖 ALFWorld、WebShop、ScienceWorld，显示 TCOD 能抑制多轮 KL 累积并改善 Agent 成功率。所以最新的多轮 Agent 路线已经变成：

Multi-turn RL + On-policy distillation + Temporal curriculum

## 九、当前研究格局

| 路线          | 蒸馏解决什么          | 代表论文                |
|-------------|-----------------|---------------------|
| RL-OPD 理论统一 | 解释蒸馏与 KL-RL 的关系 | G-OPD / ExOPD       |
| 环境反馈自蒸馏     | 稀疏奖励与信用分配       | SDPO                |
| RLVR 内自蒸馏   | token 级监督       | Self-Distilled RLVR |

| 路线              | 蒸馏解决什么                    | 代表论文         |
|-----------------|---------------------------|--------------|
| cliff prompt 路由 | 全失败组零梯度                   | HDPO         |
| 教师调制策略梯度        | 避免无条件模仿                   | Distilled RL |
| 对比自蒸馏           | 消除 privileged style drift | RLCSD        |
| 反向教师信号          | 保留学生自主探索                  | RLRT         |
| 多领域能力合并         | 避免多领域 RL 干扰与遗忘            | MOPD         |
| 多轮课程蒸馏          | 控制长轨迹误差累积                 | TCOD         |

## 十、最值得关注的趋势

### 1. 从“全样本蒸馏”转向选择性蒸馏

未来更可能采用路由：

$$L(x) = \begin{cases} L_{\text{RL}}, & \text{学生已有可探索成功率} \\ L_{\text{distill}}, & \text{所有 rollout 失败} \\ L_{\text{contrastive}}, & \text{教师信号可能含风格偏差} \\ L_{\text{exploration}}, & \text{学生正确但与教师不同.} \end{cases}$$

也就是先判断这个 prompt/rollout 需要哪种监督。

### 2. 从序列 KL 转向 token-routed distillation

并非每个 token 都需要教师：

- 关键推理分叉需要；
- 格式 token 不需要；
- 教师低置信度 token 不应强制模仿；
- 学生已经正确的高置信度 token 应保留。因此会越来越多地使用：

$$w_t = f(r, \pi_T, \pi_S, \text{uncertainty}, \text{verification}).$$

### 3. 教师不再被视为不可超越的上界

ExOPD、Distilled RL、RLRT 都在处理同一件事：

教师提供方向或知识，但最终优化目标仍然是环境 reward，而不是教师相似度。

## 4. 多教师 OPD 正在成为能力合并工具

比较现实的 frontier model 后训练管线可能是：

```
Base model
├─ Math RL teacher
├─ Code RL teacher
├─ Tool RL teacher
├─ Agent RL teacher
└─ General alignment teacher
    ↓
Multi-teacher OPD
    ↓
Unified student
    ↓
Final reward-driven RL
```

## 5. 蒸馏正在承担 RL 的“信用分配器”角色

过去知识蒸馏主要用于压缩模型；现在它越来越像一个 dense advantage estimator：

$$\text{teacher-student logit gap} \approx \text{token-level learning direction.}$$

这可能是 RL 与蒸馏融合中最重要的概念变化。

## 阅读建议

如果想快速掌握这条路线，我建议按下面顺序：

1. [On-Policy Distillation Survey](#)：建立整体框架；
2. [G-OPD / ExOPD](#)：理解 OPD 与 KL-RL 的统一；
3. [SDPO](#)：理解反馈如何转成自蒸馏；
4. [HDPO](#)：理解只在 RL 零梯度区域蒸馏；

5. [RLCSD](#): 理解自蒸馏为何会产生错误信号;
6. [Distilled RL](#): 理解教师如何直接进入 RL 梯度;
7. [MOPD](#): 理解多领域 RL 能力合并;
8. [TCOD](#): 理解多轮 Agent 的课程蒸馏。如果只看最重要的三篇, 我会选:

$G\text{-OPD} + \text{HDPO} + \text{Distilled RL}$

它们分别代表 “理论统一” “选择性混合” 和 “梯度级真正融合” 。