

前面我讲的是概念，这里我们从 **DeepSeek-V4 代码实现角度拆 mHC (Manifold-Constrained Hyper-Connections)** 。

先说明一下：mHC 不是 Attention Residual (AttnRes)。两者都在改 Transformer 的信息流，但：

- **AttnRes (Kimi K3)**：让当前层通过 attention 读取历史层输出 (depth attention)
- **mHC (DeepSeek-V4)**：让 residual connection 从固定加法变成**可学习的信息路由矩阵**

也就是：

AttnRes 是“从哪些历史层取信息”；mHC 是“当前 residual stream 中的信息如何混合”。

1. 原始 Transformer residual 的代码

标准：

```
def forward(self, x):

    residual = x

    x = self.attention(
        self.norm1(x)
    )

    x = residual + x

    residual = x

    x = self.mlp(
        self.norm2(x)
    )

    x = residual + x
```

```
return x
```

对应：

$$x_{l+1} = x_l + F_l(x_l)$$

这里 residual：

```
residual
```

只有一条路径。

2. mHC 的目标

DeepSeek-V4 想改成：

不是：

```
x
|
|
+---- F(x)
|
v
x'
```

而是：

```
x1
x2
x3
...
xm

|
```

|
Hyper Connection

|
v

mixed x

+

F(x)

也就是：

多个 residual stream。

3. Hyper-Connection 是什么？

假设：

普通 Transformer:

hidden:

$$x \in R^d$$

mHC:

扩展：

$$X \in R^{n \times d}$$

例如：

传统：

```
hidden size=4096
```

```
一个stream
```

mHC:

```
4个stream  
  
stream0  
stream1  
stream2  
stream3
```

代码类似:

```
x = x.view(  
    batch,  
    seq,  
    num_streams,  
    hidden  
)
```

例如:

```
num_streams=4
```

得到:

```
[  
    stream0,  
    stream1,  
    stream2,  
    stream3  
]
```

4. Hyper Connection 的三个矩阵

mHC 核心:

三个映射:

① Expand

把一个 stream 扩展成多个。

数学:

$$X_e = H_{exp}x$$

代码类似:

```
x = expand_proj(x)
```

例如:

输入:

```
x  
  
4096 dim
```

变:

```
4 x 4096
```

② Residual mixing

核心:

$$X' = H_{res}X$$

也就是：

不同 stream 之间通信。

例如：

矩阵：

$$H_{res} = [0.7 \quad 0.2 \quad 0.1 \quad 0.1 \quad 0.8 \quad 0.1 \quad 0.2 \quad 0.2 \quad 0.6]$$

代码：

```
x = torch.einsum(
    "ij,bjhd->bihd",
    H,
    x
)
```

含义：

stream0:

```
0.7 stream0
+0.2 stream1
+0.1 stream2
```

③ Contract

最后合并：

$$y = H_{con}X$$

代码：

```
out = contract_proj(x)
```

回：

```
4 streams

↓

1 stream
```

5. 为什么叫 Manifold-Constrained?

关键就在这里。

如果：

$$H_{res}$$

随便学习：

可能：

```
stream0
x100

stream1
x0.001
```

导致：

训练爆炸。

所以 DeepSeek 加约束。

6. 双随机矩阵约束

mHC 约束：

$$H_{res} \mathbf{1} = \mathbf{1}$$

以及：

$$H_{res}^T \mathbf{1} = \mathbf{1}$$

也就是：

每行：

sum=1

每列：

sum=1

例如：

合法：

```
0.5 0.5
0.5 0.5
```

非法：

```
10 0
0 10
```

7. 代码里面怎么保证？

源码里面类似：

```
def doubly_stochastic(
    logits
):
    A = torch.softmax(
```



```

        logits,
        dim=-1
    )

    for _ in range(k):

        A = A / A.sum(
            dim=-1,
            keepdim=True
        )

        A = A / A.sum(
            dim=-2,
            keepdim=True
        )

    return A

```

这个叫：

Sinkhorn normalization

不断：

行归一化

列归一化

最后：

得到：

$$H \in \mathcal{M}$$

即：

manifold。

8. 完整 mHC block 伪代码

接近源码逻辑：

```
class mHCBlock(nn.Module):

    def forward(self, x):

        # expand residual streams

        x = self.expand(x)

        # constrained residual mixing

        H = self.get_doubly_stochastic()

        x = torch.einsum(
            "ij,bjtd->bitd",
            H,
            x
        )

        # transformer block

        x = x + attention(x)

        x = x + mlp(x)

        # contract

        x = self.contract(x)

    return x
```

9. 一个数字例子

假设：

3 个 residual stream:

```
x0=[1,0]

x1=[0,1]

x2=[1,1]
```

学习：

$$H = \begin{bmatrix} 0.5 & 0.3 & 0.2 & 0.2 & 0.6 & 0.2 & 0.3 & 0.1 & 0.6 \end{bmatrix}$$

新的：

stream0:

$$0.5x_0 + 0.3x_1 + 0.2x_2$$

=

```
[0.7,0.5]
```

stream1:

```
[0.4,0.8]
```

于是：

下一层看到的是：

```
融合后的历史信息
```

而不是简单：




10. 和普通 residual 对比

普通

代码：




信息流：




固定。

mHC

代码：



信息流：



```
stream0
  \
stream1 ---> H ---> mixed
  /
stream2
```

动态。

11. 为什么 DeepSeek-V4 需要 mHC?

因为 V4:

1.6T 参数 MoE

层数深。

同时:

MoE:

```
● ● ●
dense attention

+
expert routing
```

会导致:

hidden representation:

- 方差变化大
- expert 输出分布不同

普通 residual:

容易:

```
● ● ●
```

早期信息被冲淡

或者：

某些 expert 输出 dominate

mHC：

相当于：

给 residual 加一个：

智能 mixer

控制信息流。

12. 和 Kimi K3 AttnRes 的本质区别

这个非常重要：

	mHC	AttnRes
解决问题	residual 信息混合	历史层选择
维度	hidden stream	depth
机制	矩阵乘	attention
公式	HX	$\text{softmax}(QK)V$
额外参数	mix matrix	$Q/K/V$
目的	稳定训练	增强深层信息利用

总结一句：

DeepSeek-V4 的 mHC 本质是把 Transformer 固定的 $x + F(x)$ residual 改成一个受约束的可学习信息混合网络：先把 hidden 扩展成多个 residual stream，通过

Sinkhorn 约束的双随机矩阵进行信息交换，再压缩回单 stream，从而让超深 MoE Transformer 的信息流更加稳定。