


下面重点讲 **DeepSeek-V4 的训练方法**，不展开架构细节（CSA/HCA/mHC），重点看它怎么把一个 **1.6T MoE 模型**训练出来，以及为什么这样训练。

DeepSeek-V4 的训练可以分成两大阶段：



论文明确说明：

- DeepSeek-V4-Flash 使用 **32T tokens** 预训练；
- DeepSeek-V4-Pro 使用 **33T tokens** 预训练；
- 之后进入完整 post-training 流程。

一、Pre-Training: 32T token 如何训练

1. 数据规模

DeepSeek-V4 不是在小数据上微调，而是完整重新预训练：

模型	参数规模	训练token
DeepSeek-V4-Flash	284B total / 13B activated	32T
DeepSeek-V4-Pro	1.6T total / 49B activated	33T

目标：

学习通用语言能力 + 长上下文能力 + MoE专家能力

2. 最大创新：渐进式长度训练 (Length Curriculum)

这是 DeepSeek-V4 训练里非常关键的一点。

它不是一开始直接训练 1M context。

训练长度：



论文明确：

training starts with sequence length of 4K, and gradually extend the training sequence length to 16K, 64K, and 1M.

为什么这么做？

因为直接训练：



```
batch:
```

```
[B, 1M]
```

```
attention:
```

```
1M × 1M
```

```
≈1012 attention matrix
```

计算和显存无法接受。

所以采用 curriculum：

短上下文阶段：



```
4K:
```

```
学习基本语言规律
```

```
↓
```

```
16K:
```

```
学习中长依赖
```

```
↓
```

```
64K:
```

```
学习文档级结构
```

```
↓
```

```
1M:
```

```
学习超长上下文能力
```

类似人学习：

先小学 → 高中 → 大学


而不是第一天直接学博士课程。

3. Attention训练策略：先dense，再sparse

DeepSeek-V4 引入 CSA/HCA。

但是训练不是直接打开稀疏 attention。

它采用：



论文：

first warmup the model with dense attention for the first 1T tokens, and introduce sparse attention at sequence length of 64K.

原因：

如果一开始：



query

只能看到top-k token

模型不知道哪些token重要。

所以：

先 dense：

学习：



token importance distribution

再切 sparse：

学习：



如何高效选择重要token

4. Lightning Indexer 的训练

CSA里面有一个关键组件：



Query

|

v

Indexer

|

v

选择top-k KV block

它负责：

长文本里面：

100万个token

↓

选择几百个关键区域

但是这个indexer不是随机初始化直接使用。

训练流程：



论文：

When introducing attention sparsity, we first set a short stage to warm up the lightning indexer in CSA.

这个很重要。

类似检索系统：

不能一开始就相信retriever。

必须先训练一个好的retrieval能力。


5. Optimizer: Muon替代AdamW

DeepSeek-V4 一个非常大的变化：

使用 Muon optimizer。

不是所有参数：

而是：



论文说明：

DeepSeek-V4-Pro：

employ Muon optimizer for majority of parameters, but use AdamW for embedding, prediction head and RMSNorm.

为什么？

因为1T级MoE：

Adam状态巨大：

Adam需要：



例如：

1.6T参数：

optimizer state可能超过模型本身。

Muon优势：

降低optimizer memory。

同时：

论文认为：

- 更快收敛
- 更稳定

6. Learning Rate策略

DeepSeek-V4-Flash:

大致:

```
warmup:  
  
2000 steps  
  
peak LR:  
  
2.7e-4  
  
最后:  
  
2.7e-5
```

采用:

cosine decay

DeepSeek-V4-Pro:

```
peak LR:  
  
2.0e-4  
  
end LR:  
  
2.0e-5
```

7. Batch size变化

它采用 batch scheduling。

原因:

训练初期：

模型还没稳定：

小batch更安全。

后期：

增加batch：

提高吞吐。

DeepSeek-V4-Pro：


最大 batch：

94.4M tokens

也就是说：

一次训练step：

接近：




8. MTP Loss训练

DeepSeek-V4 保留 DeepSeek-V3 的 Multi Token Prediction。

训练目标：

不是只预测：



而是：

同时预测：

```
x(t+1)
x(t+2)
x(t+3)
...
```

Loss:

```
Loss =
LM Loss
+
λ MTP Loss
```

其中：

大部分训练：

```
λ=0.3
```

学习率衰减阶段：

```
λ=0.1
```

9. MoE训练稳定性

1.6T MoE 最大问题：

不是算力。

而是：

expert collapse / routing instability

论文指出：

训练过程中loss spike:

主要来自:

```
MoE layer outliers  
  
+  
  
routing amplification
```

解决:

(1) Auxiliary-loss-free load balancing

传统MoE:

加入:

```
balance loss
```

但是:

可能损害主任务。

DeepSeek采用:

```
bias based balancing
```

同时增加:

sequence-wise balance loss:

防止单个sequence极端失衡。

参数:

```
bias update speed=0.001

balance loss weight=0.0001
```

二、Post-Training：如何变成推理模型

预训练之后：

得到：



```
DeepSeek-V4-Base
```


还不是聊天模型。

然后：

Stage 1: Domain Specialist Training

针对不同能力：

训练不同专家：



论文：

领域包括：

- mathematics
- coding
- agent
- instruction following

每个领域：

流程：



Stage 2: On-policy Distillation

问题：

多个专家：



Math expert

Code expert

Agent expert

如何合成一个模型？

DeepSeek采用：

On-policy Distillation。

结构：

Teacher models

(Math/Code/Agent)

|

v

Student unified model

优化：

reverse KL loss


即：


让student靠近多个teacher分布。

论文：

unified model acts as student learning to optimize reverse KL loss with teacher models.

三、整个训练流程总结图





和 DeepSeek-V3 相比，训练最大的变化

方向	DeepSeek-V3	DeepSeek-V4
数据	14.8T tokens	32T/33T tokens
长度	128K	1M
Attention	MLA	CSA+HCA
Optimizer	AdamW	Muon+AdamW
MoE稳定	aux loss	bias balancing
训练长度	固定	4K→16K→64K→1M
RL	单模型强化	多专家+OPD

如果从训练工程角度看，DeepSeek-V4 最大的贡献其实不是单个算法，而是：

把一个1.6T MoE模型训练到1M context: 长度课程学习 + Dense→Sparse Attention切换 + Muon优化器 + MoE稳定机制 + 后训练专家蒸馏。

这套训练范式更接近下一代超大模型（GPT-5级别）路线。