

DeepSeek 系列模型发展历程

LLM · MoE · 推理：架构、训练与系统协同演进

本报告梳理 DeepSeek 从早期语言模型、DeepSeek-Coder、DeepSeekMath，到 V2/V2.5、V3、R1、V3.2-Exp 及 2026 年 V4/Pro 公开信息的技术演进。重点解释 MLA、DeepSeekMoE、无辅助损失负载均衡、MTP、GRPO 和推理系统协同。

主线	覆盖内容
语言与代码	DeepSeek-LLM、Coder、Coder-V2、Math
架构主线	DeepSeek-V2、V2.5、V3、V3.2-Exp
推理主线	R1-Zero、R1、蒸馏模型与后续 R1 更新
下一代方向	DeepSeek-V4/Pro：以公开论文、技术材料和已披露信息为准；未公开细节不作确定性判断

一、全局路线：DeepSeek 的核心贡献

DeepSeek 的技术路线可以概括为“架构压缩 + 稀疏激活 + 训练系统协同 + 可验证推理”。V2 首次把 MLA 与 DeepSeekMoE 组合成可规模化架构；V3 将其扩大到 671B 总参数、37B 激活，并用 FP8、无辅助损失负载均衡和 MTP 进一步降低训练/推理成本；R1 则把重点从“模型容量”转向“通过 RL 激发推理”。

阶段	代表模型	关键变化	训练关键词
基础探索	DeepSeek-LLM / Coder / Math	建立数据、代码和数学能力；探索 scaling 与领域继续预训练	预训练、SFT、代码执行、数学数据
架构重构	V2 / V2.5	MLA、DeepSeekMoE、细粒度专家、共享专家	高质量数据 + MoE 训练
规模化与系统协同	V3	671B/37B；FP8；无辅助损失负载均衡；MTP	14.8T token；SFT + RL
推理时代	R1-Zero / R1	纯 RL 激发推理；冷启动 SFT + RL；蒸馏	GRPO、规则奖励、拒绝采样
下一代	V3.2-Exp / V4/Pro	稀疏注意力、长上下文、视觉/多模态和系统协同方向	公开细节不完整

二、早期模型：DeepSeek-LLM、Coder 与 Math

分支	架构与定位	训练变化	技术意义
DeepSeek-LLM	通用 decoder-only 语言模型，覆盖 7B/67B 等规模	强调数据质量、中文/英文混合和 scaling law；base 后进行 instruction tuning	建立后续 MoE 和推理模型的语言底座
DeepSeek-Coder	代码专用语言模型；代码与自然语言混合建模	大规模代码继续预训练；仓库级数据、跨语言代码和代码-文本配比；指令微调	代码能力成为 DeepSeek 系列的重要支柱
DeepSeek-Coder-V2	基于 MoE，扩展到更大总参数与更长上下文；支持大量编程语言	代码继续预训练、代码指令、数学和执行反馈	验证 MoE 在代码和推理任务上的高性价比
DeepSeekMath	基于 Coder 底座的数学专家模型	约 120B 数学相关 token；GRPO 等 RL 探索；工具辅助推理	为 R1 的可验证奖励与数学推理奠定基础

早期阶段的关键不是提出一个完全不同的 Transformer，而是通过代码/数学数据和执行反馈，把“模型生成答案”转变为“模型能够验证和修正答案”。

三、DeepSeek-V2：MLA 与 DeepSeekMoE

DeepSeek-V2 是架构路线的分水岭。其核心目标是：在扩大总参数容量的同时，减少 KV cache、降低每 token 激活量，并让专家路由在分布式训练中更可控。

MLA (Multi-head Latent Attention)

MLA 对 attention 的 key/value 做低秩联合压缩：模型在计算时恢复所需的 K/V 表示，但缓存阶段主要保存低维 latent 和必要的 positional 部分。与标准 MHA 相比，它显著减少 KV cache；与普通 MQA/GQA 相比，它尽量保留多头注意力的表达能力。

DeepSeekMoE

DeepSeekMoE 使用细粒度专家，把 FFN 的容量拆成更多小专家，并为每个 token 路由少量专家；同时保留共享专家处理所有 token 的通用知识。共享专家与路由专家的分工，缓解了“所有专家都学习重复通用知识”的问题。

训练与系统含义

MoE 让参数、计算和通信分离：总参数可以很大，但每 token 只激活部分专家；代价是 expert parallel 的 All-to-All。MLA 降低 decode 阶段 KV 读写，MoE 则增加 token dispatch/Combine 通信，因此 DeepSeek 的高性能依赖通信与计算重叠、专家负载平衡和专用 kernel。

四、DeepSeek-V3：规模化、稳定训练与系统协同

项目	公开信息	作用
模型规模	671B 总参数，37B 每 token 激活	以稀疏激活获得大容量和较低 token 计算
注意力	延续 MLA	降低 KV cache，改善推理内存和带宽压力
MoE	延续 DeepSeekMoE；细粒度专家 + 共享专家	扩大专家容量，控制激活参数
负载均衡	auxiliary-loss-free load balancing；通过偏置调整路由倾向	减少辅助损失对主任务的干扰和性能退化
训练精度	FP8 mixed-precision training；关键部分保持更高精度	降低显存与通信成本，并配合数值稳定策略
训练目标	Multi-Token Prediction（MTP）	训练时预测多个未来 token；增强表示和为 speculative decoding 提供基础
训练规模	14.8T 高质量 token；2.788M H800 GPU hours；无不可恢复 loss spike/rollback	体现数据、硬件、并行和训练稳定性的共同优化

V3 的创新不是单个模块，而是“架构—精度—并行—数据—目标函数”的联合设计：MLA 解决缓存，MoE 解决参数/计算，FP8 解决成本，负载均衡解决路由，MTP 兼顾训练效果和推理加速。

五、DeepSeek-R1：从预训练规模到推理训练

R1

的根本变化是把推理能力视为可以通过强化学习激发的行为，而不是完全依赖人工标注的长思维链。R1-Zero 直接从 V3-Base 出发使用规则奖励进行 RL；R1 在此基础上加入冷启动数据、拒绝采样、SFT 和多阶段 RL，以改善可读性、通用性和稳定性。

阶段	做法	目的
R1-Zero	V3-Base + 大规模 RL；数学/代码等任务使用可验证规则奖励	观察 self-reflection、verification、动态策略等推理行为自然出现
冷启动	整理高质量长 CoT、加入推理格式和通用能力数据	避免纯 RL 初期输出难读、语言混杂和泛化不足
拒绝采样 + SFT	从模型生成结果中筛选正确推理轨迹，结合通用指令数据微调	把 R1-Zero 的推理模式转化为更稳定的训练起点
多阶段 RL	推理任务使用规则奖励；通用任务使用偏好/奖励模型，并处理长度与语言一致性	兼顾正确性、帮助性、格式、语言和回答长度
蒸馏	将 R1 的推理轨迹蒸馏到 Qwen、Llama 等 1.5B-70B 模型	把大模型推理能力迁移到低成本小模型

GRPO 的直观逻辑：对同一问题采样一组回答，用组内相对奖励估计优势，不必单独训练传统 value model；再结合 KL 约束更新策略。对于多奖励任务，奖励组合与归一化方式会显著影响“正确率—长度—格式”的权衡。

六、V3.2-Exp 与 V4/Pro：如何区分事实和推测

V3.2-Exp 在 2025 年被官方描述为通向下一代架构的中间实验版本，重点引入 DeepSeek Sparse Attention，目标是降低长序列处理成本并改善效率。它应被理解为架构试验，而不是简单的 V3 小版本。

关于 DeepSeek-V4/Pro：公开材料、模型服务名和社区讨论已经出现下一代模型线索，但完整的官方技术报告、结构图、训练数据规模和每阶段配方并不总是同步公开。因此本报告只保留可以确认的分析框架：

- 重点方向很可能继续围绕稀疏注意力、低 KV 成本、MoE/专家路由、长上下文和多模态/视觉能力展开。
- 对推理服务而言，需要同时考虑 MLA 或其后续缓存压缩、MoE Expert Parallel、All-to-All、MTP/投机解码、PD 分离和通信计算重叠。
- V4-Pro 不能仅凭 API 名称推断其是否完全更换骨干；必须以官方 config、model.py、论文或技术报告为准。
- 用户此前关注的 FP4 indexer、mHC、HiSparse、waterfill、LPLB、MegaMoE 等属于模型/推理系统协同问题，分析时应区分“模型原生结构”和“后端优化实现”。

七、DeepSeek 训练演进总结

维度	早期	V2/V3	R1 以后
数据	通用文本、代码、数学	高质量过滤、领域数据、14.8T 规模	可验证问题、长 CoT、模型生成和拒绝采样
架构	Dense Transformer	MLA + DeepSeekMoE + FP8	沿用 V3 骨干，主要在推理后训练上创新
监督训练	常规 SFT	代码/数学/工具指令	冷启动、推理轨迹筛选、多阶段 SFT
强化学习	较弱或传统偏好优化	V3 的通用 RL	规则奖励、GRPO、长度/语言/帮助性综合奖励
系统	常规并行	EP、TP、通信重叠、FP8、MTP	推理服务与训练目标共同设计，支持长思考和投机解码

一句话总结：DeepSeek 的“高性价比”来自系统工程闭环，而不是单一技巧。MLA、MoE、FP8、负载均衡、MTP 和 RL 推理训练彼此相互支撑。

八、DeepSeek-V3.2：从实验版到正式报告

V3.2-Exp 是建立在 V3.1-Terminus 上的实验版本；正式 V3.2 则把 DSA、可扩展 RL 和 Agentic Task Synthesis 纳入完整模型路线。其核心不是“只把全注意力裁稀疏”，而是用 lightning indexer 先对历史 token 做高效检索，再进行细粒度 top-k token 选择，最终只对被选 token 做主要注意力计算。

模块	正式报告中的变化	意义
DSA	DeepSeek Sparse Attention；indexer + fine-grained token selection；面向长上下文	把注意力复杂度从全历史访问转向近似稀疏访问，降低长上下文训练和推理成本
后训练 RL	扩大 RL 计算，构建可扩展、稳定的强化学习协议	让推理能力、工具使用和复杂任务泛化不再只依赖预训练规模
Agent 数据	大规模合成工具使用环境、复杂提示和交互轨迹	将推理能力迁移到真实工具调用、长流程 Agent 任务
Speciale	高计算推理变体；在数学和代码竞赛任务上强化	用额外后训练计算换取更强的深度推理能力

九、DeepSeek-V4：百万 token 与混合注意力

DeepSeek-V4 报告把目标从“更大的稀疏模型”推进到“高效处理百万 token 上下文”。公开报告给出两个 MoE 模型：DeepSeek-V4-Pro 总参数约 1.6T、每 token 激活约 49B；DeepSeek-V4-Flash 总参数约 284B、每 token 激活约 13B；两者上下文长度均为 1M token。

组件	V4 公开设计	解决的问题
混合注意力	CSA (Compressed Sparse Attention) 与 HCA (Heavily Compressed Attention) 组合；不同层/场景采用不同压缩强度	在长上下文中降低注意力计算与 KV/状态存储，同时保留局部和关键上下文能力
mHC	Manifold-Constrained Hyper-Connections；对残差连接的多路扩展施加流形约束	提高深层/宽残差路径训练稳定性，减少超连接导致的数值发散
优化器	Muon optimizer；报告强调更快收敛与训练稳定性	在大规模训练中改善优化效率，减少同等质量所需更新成本
MoE	延续稀疏专家路线；Pro/Flash 在总参数与激活参数上面向不同吞吐-质量权衡	分别服务复杂 Agent/代码推理与高吞吐、低成本场景
硬件与系统	V4/Pro 公开材料强调对新型国产加速器和软硬件栈的适配	把模型结构、通信、算子和硬件适配纳入共同设计

V4 的主线不是简单地把 V3 的 MLA 换成一个稀疏注意力模块，而是同时重做长上下文注意力、残差连接稳定性、优化器和软硬件协同。对于推理实现，应分别分析 CSA/HCA 的 token 选择与压缩路径、mHC 的残差计算、MoE 的 Expert Parallel，以及百万上下文下的 KV/状态管理。

十、V3 → R1 → V3.2 → V4：连续演进

版本	主要矛盾	解决方案	训练变化
V3	总参数大、每 token 计算和 KV 成本高	MLA + DeepSeekMoE + FP8 + 无辅助损失负载均衡 + MTP	14.8T token；SFT + RL；稳定训练
R1	通用模型会答，但复杂推理不稳定	规则奖励、GRPO、多阶段 RL、冷启动和蒸馏	把推理作为可学习行为，扩大后训练计算
V3.2	百万/超长上下文下全注意力成本过高，Agent 任务数据不足	DSA；可扩展 RL；大规模 Agentic Task Synthesis	长上下文稀疏注意力与工具交互联合后训练
V4	百万 token、深层超宽网络和大规模训练稳定性	CSA + HCA；mHC；Muon；Pro/Flash 双路线	面向百万上下文与软硬件协同的预训练/优化

十一、资料来源

优先使用论文、官方仓库和技术报告：

DeepSeek-LLM: <https://arxiv.org/abs/2401.02954>

DeepSeek-Coder: <https://arxiv.org/abs/2401.14196>

DeepSeekMath: <https://arxiv.org/abs/2402.03300>

DeepSeek-V2: <https://arxiv.org/abs/2405.04434>

DeepSeek-V2.5: <https://huggingface.co/deepseek-ai/DeepSeek-V2.5>

DeepSeek-V3 Technical Report: <https://arxiv.org/abs/2412.19437>

DeepSeek-R1 Technical Report: <https://arxiv.org/abs/2501.12948>

DeepSeek-V3.2 Technical Report: <https://arxiv.org/abs/2512.02556>

DeepSeek-V3.2-Exp 官方仓库: <https://github.com/deepseek-ai/DeepSeek-V3.2-Exp>

DeepSeek-V4 Technical Report: <https://arxiv.org/abs/2606.19348>

DeepSeek-V4-Pro 模型卡: <https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro>

DeepSeek 官方组织: <https://github.com/deepseek-ai>

说明：本次修订已将 V3.2 正式报告和 V4 正式报告纳入正文；V4/Pro 的公开报告细节与具体部署实现仍需以官方代码、配置和后续更新为准。

正式报告补充：训练与基础设施

DeepSeek-V3.2 正式报告进一步明确：V3.2 的后训练不仅是常规 RL，而是可扩展 RL 协议与大规模 Agentic Task Synthesis 的组合；通过工具环境生成复杂交互轨迹，把推理能力迁移到搜索、代码和长流程 Agent 任务。DSA 的实现由 lightning indexer 与细粒度 token 选择组成，先检索再稀疏注意力。

DeepSeek-V4 正式报告给出更完整的训练闭环：V4-Flash 预训练 32T token，V4-Pro 预训练 33T token；后训练先分别训练数学、代码、Agent、指令跟随等领域专家，再通过 on-policy distillation 统一，统一模型以 reverse-KL 学习专家教师。

V4 的工程部分同样是报告的重要内容：MoE 融合 kernel 同时重叠计算、通信和访存；使用 TileLang、batch-invariant deterministic kernel；训练框架加入 Muon 的 hybrid ZeRO、mHC 的重计算/融合、two-stage contextual parallelism；推理框架使用异构 KV cache 和磁盘 KV cache；后训练加入 MoE expert 与 indexer QK 路径的 FP4 quantization-aware training。

这说明 V4 的提升不是单一注意力算法替换，而是“CSA/HCA + mHC + Muon + 上下文并行 + KV 管理 + FP4 QAT + 专家蒸馏/RL”的整体系统设计。