


下面先**重点介绍 GLM-5 的模型结构 (Architecture)**，暂时不展开训练流程和 RL。
GLM-5 的核心变化可以概括为：

在 GLM-4.5 的 MoE 基础上，引入 DeepSeek Sparse Attention (DSA) + MLA-256 + 参数共享 MTP，将模型规模扩展到 744B，同时保持 40B 激活参数，使其适合长上下文 Agent 场景。

整体结构如下：



1. GLM-5 整体规模

GLM-5 是一个 **Mixture-of-Experts (MoE) Transformer**。

论文给出的核心配置：

项目	GLM-5
总参数	744B
激活参数	40B
Expert数量	256 experts

项目	GLM-5
Transformer层数	80 layers
Attention	MLA + DSA
最大上下文	200K
训练token	28.5T

相比 GLM-4.5:

	GLM-4.5	GLM-5
总参数	355B	744B
激活参数	32B	40B
Expert	?	256
Layers	更多	80
Attention	普通结构	DSA
Context	128K	200K

论文指出:


GLM-5 将 expert 数扩展到 256，同时降低 layer 数到 80，以减少 expert parallelism 带来的通信开销。

2. Backbone: MoE Transformer

GLM-5 主体仍然是:



每个 Transformer block:




3. MoE 部分: 256 Expert

GLM-5 延续 DeepSeek 系列路线:

不是 dense FFN:



而是:





每个 token 不会访问 256 个 expert。

只激活：



Top-k experts

因此：

744B 参数

但是：



每个token只计算40B参数

这也是 MoE 能扩展超大模型的原因。

4. Attention 最大创新： MLA + DSA

这是 GLM-5 架构最核心变化。

4.1 MLA (Multi-head Latent Attention)

GLM-5 使用:

Multi-latent Attention (MLA)

来源于 DeepSeek-V2/V3。

传统 MHA:

$$Q = XW_q$$

$$K = XW_k$$

$$V = XW_v$$

Attention:

$$\text{softmax}(QK^T)V$$

问题:

KV Cache巨大。

例如:

128K context:

$$\text{KV cache} \propto \text{sequence length}$$


长上下文推理显存爆炸。

MLA 思路:

不直接保存:

K
V

而保存一个压缩 latent:



也就是:

KV cache:

以前:

[K1,V1]
[K2,V2]
...
[Kn,Vn]

MLA:

[c1]
[c2]
...
[cn]

所以：

KV cache 大幅降低。

4.2 GLM-5 对 MLA 的改进：Muon Split

论文发现：

原始 MLA：



```
latent KV = 576 dim
```

效果无法超过：

GQA-8:



```
KV cache = 2048 dim
```

原因：

不同 attention head 更新尺度不一致。

于是提出：

Muon Split

原来：



```
WUQ
```

一个大矩阵统一正交化

改成：



```
head1:
```

```
WUQ1
```

```
head2:
```

```
WUQ2
```

```
head3:
```

```
WUQ3
```

```
分别优化
```

效果：



不同head拥有独立更新尺度

提升 MLA 能力。

论文 Table 1 表明：

MLA + Muon Split 可以达到甚至接近 GQA-8。

5. MLA-256：针对 Decode 优化

这是非常工程化的优化。

DeepSeek-V3 MLA：



```
head dim =192
```

```
attention heads 多
```

Decode阶段：

需要：



q × latent KV

计算量较大。

GLM-5 改：

head dim:

192 → 256

head数量：

减少1/3

保持：

参数量不变

训练计算不变

但是：

decode attention计算降低。

论文：

MLA-256 matches MLA performance while decreasing decoding computation.

对于推理系统来说：

这是非常关键的。

因为：

prefill:

计算密集

decode:

memory bandwidth sensitive

减少 decode attention:

直接提升 tok/s。

6. DSA: DeepSeek Sparse Attention

这是 GLM-5 最大架构创新。


传统 Attention:



复杂度:

[$O(L^2)$]

128K:




不可接受。

DSA:


核心:

动态选择重要 token，而不是全部计算。

结构:



Indexer类似:



先判断:

哪些历史token重要。


然后:

只对这些计算attention。


例如:

128K context:

传统:




DSA:



论文指出:

DSA可以减少:




并保持长上下文能力。

7. DSA 和 MLA 的组合

GLM-5 Attention:

不是:



MLA

而是：



两者解决不同问题：

技术	解决
MLA	KV cache
DSA	Attention FLOPs

所以：

长上下文 Agent：

同时受益。

8. MTP: Multi Token Prediction


GLM-5 也加入 MTP。

目的：

- 1. 提升模型能力
- 2. speculative decoding 加速


传统：

一次预测：




MTP:

同时预测：




结构：



GLM-5 特殊设计：


参数共享 MTP

普通：



参数增加。

GLM-5：



优点：


训练显存不增加。

论文：

GLM-5 使用共享3个MTP层，提高 speculative decoding acceptance length。

9. 最终 GLM-5 架构总结图





和 DeepSeek-V3/V4 的关系

如果你熟悉 DeepSeek 系列，可以这样理解：

	DeepSeek-V3	GLM-5
MoE	✓	✓
MLA	✓	✓
DSA	V3.2开始	✓
MTP	✓	✓
长上下文优化	MLA	MLA+DSA
专家规模	256	256
目标	通用LLM	Agent工程

一句话总结

GLM-5 本质是一个 DeepSeek 系路线的超大 MoE Transformer: 用 256 Expert 扩大参数容量, 用 MLA 压缩 KV Cache, 用 DSA 动态稀疏 Attention 降低长上下文计算, 再配合共享参数 MTP 提升推理速度, 最终服务于 200K 长上下文 Agent 编程场景。