

GLM 系列模型发展历程

从 GLM-130B、ChatGLM 到 GLM-5：架构、训练与智能体演进

本报告梳理 GLM 系列从 GLM-130B、ChatGLM、GLM-4 到 GLM-4.5、GLM-4.6V、GLM-5 的发展。重点分析双语语言模型、长上下文、多模态、MoE、MLA/DSA、混合推理、Agent RL 和异步训练基础设施。

主线	代表内容
早期底座	GLM-130B、ChatGLM-6B、ChatGLM2/3
GLM-4	GLM-4、GLM-4-Air、GLM-4-9B、GLM-4V、All Tools
Agent 与推理	GLM-4.5/4.5-Air、GLM-Zero、混合思考
新一代	GLM-4.6V、GLM-5：DSA、MoE、异步 Agent RL

一、GLM 路线的三次跃迁

GLM 的路线可概括为：双语预训练底座 → 对话与工具增强 → 视觉/长上下文 → MoE 统一推理、代码和 Agent → 面向长周期软件工程的异步强化学习。GLM-4.5 开始，模型目标从“回答问题”明显转向“在环境中完成任务”；GLM-5 则把训练基础设施本身作为模型能力的一部分。

阶段	模型	结构/能力变化	训练变化
双语底座	GLM-130B	130B 双语预训练模型；GLM 自回归空白填充目标	中英混合预训练，建立大规模双语底座
开源对话	ChatGLM-6B/2/3	面向消费级显卡的小模型；对话模板、量化、长上下文逐代增强	监督微调、偏好对齐、工具和安全数据
通用与多模态	GLM-4/4V/All Tools	10T token、128K/1M 长上下文、视觉输入、浏览器/代码工具	多阶段 SFT + 人类反馈；工具使用对齐
Agent MoE	GLM-4.5	355B/32B 激活；Air 106B/12B 激活；思考/非思考统一	23T token；专家模型迭代、SFT、RL、蒸馏
Agentic Engineering	GLM-5	744B/40B 激活；256 experts、80 layers；MLA/DSA；200K	28.5T；长上下文中训；Reasoning/Agent/General RL；异步 RL

二、GLM-130B 与 ChatGLM：底座到对话

GLM-130B 是中英双语 130B 预训练模型，采用 GLM（General Language Model）目标，将自回归预测与空白填充结合：给定被打乱或挖空的片段，模型既学习从左到右生成，也学习根据上下文恢复缺失内容。与纯 decoder-only next-token 目标相比，GLM 目标更强调双向上下文利用。

ChatGLM 系列则将大底座压缩到更易部署的规模，并通过对话格式、监督微调、偏好数据和量化优化提升可用性。ChatGLM-6B 及后续 ChatGLM2/3

的关键贡献不是彻底更换骨干，而是把中文对话、长上下文、低显存推理和开源生态做成完整产品链。

训练变化：预训练语言知识 → 指令 SFT → 人类偏好/安全对齐 → 工具调用与代码执行。这个阶段为 GLM-4 的 “All Tools” 奠定了训练范式。

三、GLM-4：通用、多模态与工具

方向	架构/产品	训练与能力
GLM-4	通用大语言模型；GLM-4、Air、9B；支持 128K，部分版本扩展到 1M	约 10T token，主要中英数据并覆盖 24 种语言；多阶段 SFT 与人类反馈对齐
GLM-4V	视觉编码器连接 GLM-4 语言骨干；图像理解和文档能力	图文对齐、视觉指令微调、OCR/图表/空间理解
GLM-4 All Tools	模型可判断何时调用浏览器、Python、文生图和用户函数	工具轨迹、结果反馈、函数调用和多工具组合训练
GLM-4-32B-0414	32B 开源系列；对话、推理、rumination 分支	15T 高质量数据，包含大量合成推理数据，为后续 RL 做准备

GLM-4 阶段的关键变化是“模型输出答案”转向“模型决定是否调用工具并完成任务”。长上下文和工具调用不只依赖推理时 prompt，还要求训练数据包含工具选择、参数生成、工具结果读取和失败恢复。

四、GLM-4.5：ARC 与 MoE 混合推理

GLM-4.5 将 Agentic、Reasoning、Coding（ARC）作为统一目标。模型采用稀疏 MoE：GLM-4.5 为 355B 总参数、32B 激活，GLM-4.5-Air 为 106B 总参数、12B 激活；两者都支持 thinking 与 non-thinking 两种模式。

阶段	训练做法	作用
预训练	23T tokens；通用文本、代码、数学、Agent 和多语言数据	建立 ARC 统一底座
专家迭代	分别培养 reasoning、coding、agent、chat 等能力专家	避免单一模型在不同目标间互相干扰
SFT	高质量指令、长思维链、工具轨迹和 atomic skills	形成可控的推理和工具行为
RL	GRPO/结果奖励/环境执行反馈；沙箱中完成代码和 Agent 任务	把静态能力转化为可执行任务成功率
统一与蒸馏	专家模型迭代、联合 RL、蒸馏到统一模型	兼顾快速回答、深度思考和 Agent 行为

五、GLM-5：DSA、MoE 与异步 Agent RL

项目	公开规格/设计	技术意义
规模	744B 总参数、40B 激活、256 experts、80 layers；约 28.5T tokens	扩大总容量但保持每 token 激活成本可控
注意力	MLA/压缩 KV 路线与 DeepSeek Sparse Attention；约 200K context	降低长上下文训练和推理的 token 访问、KV cache 与带宽成本
长上下文中训	4K→更长 context 的阶段化训练，逐步扩展到 200K；进行 DSA adaptation	让模型适应稀疏注意力和长上下文，而不是只在推理端裁剪
后训练	Reasoning RL → Agentic RL → General RL；跨阶段 on-policy distillation	分别优化推理、工具/环境交互和通用对话，再合并能力
Agent RL	异步 rollout/训练解耦；TITO、双侧重要性采样、DP-aware routing	支持长时程、多轮工具轨迹，提升 RL 吞吐与样本新鲜度

GLM-5 的核心转变：训练系统从同步“采样一批—更新一次”转为异步持续学习。环境覆盖软件工程、终端和多跳搜索任务；模型在真实执行结果、失败恢复和长周期规划中获得 Agent 能力。

六、GLM-5 训练流程拆解

Base pretraining: 以约 28.5T token 训练通用 MoE 底座，数据覆盖文本、代码、数学、推理和 Agent 相关内容。

Context mid-training: 先在较短上下文建立基础能力，再阶段化扩展到 128K/200K；在这一阶段适配稀疏注意力、长上下文位置和高效上下文并行。

Reasoning RL: 使用数学、代码和可验证任务奖励训练深度推理；通过轨迹筛选、奖励模型/规则奖励和 on-policy 数据提高正确率。

Agentic RL: 将 rollout 与 trainer 解耦，异步生成大量工具交互轨迹；TITO 修正策略版本差异，双侧重要性采样提高 off-policy 数据利用，DP-aware routing 处理分布式 rollout。

General RL: 在推理和 Agent 能力基础上进行通用帮助性、指令跟随、安全和风格对齐。跨阶段蒸馏将不同阶段能力合并，避免最后阶段覆盖前面能力。

七、GLM 系列对比总结

版本	矛盾点	解决方案	训练范式
GLM-130B	双语大模型能力	GLM 预训练目标与大规模双语数据	预训练
ChatGLM	大模型难部署、难对话	小模型、量化、对话模板、SFT	SFT/偏好对齐
GLM-4	通用模型不会用工具/看图	长上下文、视觉、All Tools	SFT + 人类反馈 + 工具轨迹
GLM-4.5	推理、代码、Agent 相互竞争	MoE、thinking/non-thinking、专家迭代	23T + SFT + RL + 蒸馏
GLM-5	长时程 Agent RL 成本高	DSA、异步 RL、TITO、跨阶段蒸馏	28.5T + 中训 + 三阶段 RL

一句话总结：GLM 系列从“语言模型架构创新”逐步转向“模型、数据、环境、训练系统和硬件共同设计”。

八、资料来源

GLM-130B: <https://openreview.net/forum?id=-Aw0rrrPUF>

ChatGLM family / GLM-4: <https://arxiv.org/abs/2406.12793>

GLM-4.5 Technical Report: <https://arxiv.org/abs/2508.06471>

GLM-4.5 官方介绍: <https://z.ai/blog/glm-4.5>

GLM-5 Technical Report: <https://arxiv.org/abs/2602.15763>

GLM-5 官方仓库: <https://github.com/zai-org/GLM-5>

GLM-4-9B / GLM-4V: <https://github.com/THUDM/GLM-4>

GLM-4.6V: <https://z.ai/blog/glm-4.6v>

说明：GLM-4.6V、GLM-5.1/5.2 等后续版本已作为产品/模型分支出现；若需要，我可以继续把它们单独扩展为“GLM-5 之后”专题，并逐项补充正式技术报告中的架构和训练细节。

九、GLM-5 之后：GLM-5.1、GLM-5.2 与多模态分支

版本	定位/公开变化	技术演进
GLM-4.6V	106B 与 9B Flash 多模态模型；128K；原生视觉 Function Calling	视觉输入直接参与工具调用；支持交错图文生成和视觉 Agent 闭环
GLM-5.1	面向更长 Agent 任务；在 GLM-5 基础上强化长时程执行	持续规划、反思、实验、读取结果和数百轮工具调用；重点是 Agent 后训练与长周期稳定性
GLM-5.2	2026 年最新旗舰，面向 long-horizon tasks；官方 SDK/平台已列出该模型	相对 GLM-5.1 强化推理、代码、Terminal、MCP 和工具 Agent；公开资料强调多档 thinking effort 与更长任务持续性
GLM-5V-Turbo	原生多模态基础模型方向	把视觉感知作为推理、规划、工具调用和执行的核心，而不是语言模型外挂视觉接口
GLM-OCR / GLM-TTS	文档 OCR 与语音生成专用模型	GLM-OCR 使用 CogViT + GLM decoder + MTP；GLM-TTS 使用 AR text-to-token + diffusion token-to-waveform，并用 GRPO 多奖励优化

因此，完整 GLM 时间线不能停在 GLM-5：GLM-5.1/5.2 是 Agent 长时程能力的后续产品线，GLM-4.6V/5V-Turbo 是多模态 Agent 线，GLM-OCR/TTS 则是面向具体模态任务的专用分支。

资料补充：GLM-5.2 官方博客 <https://z.ai/blog/glm-5.2>；GLM-5/5.1/5.2 官方仓库 <https://github.com/zai-org/GLM-5>；GLM-4.6V <https://github.com/zai-org/GLM-V>；GLM-5V-Turbo <https://arxiv.org/abs/2604.26752>；GLM-OCR <https://arxiv.org/abs/2603.10910>；GLM-TTS <https://arxiv.org/abs/2512.14291>

十、GLM-5.1/5.2 纳入架构主线

GLM-5.1 不是简单的版本号更新，而是沿用 GLM-5 的 744B/40B 激活稀疏 MoE、MLA+DSA 和长上下文骨干，把架构能力更多转化为长时程 Agent 行为：模型能够拆解问题、运行实验、读取结果、识别阻塞并反复修正策略，在数百轮迭代和数千次工具调用中保持有效。其主要增量位于持续 Agent 后训练、长轨迹数据和更强的推理/工具调度。

GLM-5.2 的结构增量则更明确：它把上下文从 GLM-5 的约 200K 扩到 1,048,576 token，并在 DSA 上引入 IndexShare。常规模式是“full, shared, shared, shared”：每四个稀疏注意力层只运行一次独立 indexer，后面三层复用被选 token 的位置；后续层仍自行计算 query、attention 权重、value 聚合和 FFN，因此复用的是 token selection，不是复用完整注意力输出。该设计在 1M context 下将每 token FLOPs 降低约 2.9 倍。

组件	GLM-5/5.1	GLM-5.2 的架构增量
MoE	744B 总参数、约 40B 激活；256 routed experts, 8 experts/token + shared expert	沿用主干配置；重点是把同一稀疏 MoE 骨干用于 1M context 与更长 Agent 任务
注意力	MLA + DSA；GLM-5 约 200K context	IndexShare：每四层共享一次 DSA indexer 的 token selection；context 扩至 1,048,576
MTP	用于 speculative decoding	首个 draft step 计算 index，后续 draft steps 复用 index 与 KV；结合 rejection sampling 和 total-variation loss，平均接受长度约 4.56→5.47，提升约 20%
训练/后训练	异步 Agent RL、长时程工具轨迹、reasoning effort	IndexShare 在 128K continued mid-training 中适配，而非只在推理阶段外挂 cache；多档 thinking effort 平衡质量与延迟

因此，GLM-5.1 的核心增量主要在长时程 Agent 后训练和持续执行能力；GLM-5.2 的核心增量则同时落在架构和推理系统：IndexShare 减少 DSA indexer 重复计算，MTP 改进提升投机解码接受长度，最终共同服务百万 token 长上下文。

资料：GLM-5/5.1/5.2 官方仓库 <https://github.com/zai-org/GLM-5>；GLM-5.2 官方博客 <https://z.ai/blog/glm-5.2>；IndexShare 架构说明 <https://arxiv.org/abs/2605.20236>