

Kimi 系列模型发展历程

从长上下文对话、Kimi k1.5 到 K2.5/K3：架构、训练与 Agent 演进

本报告梳理 Moonshot AI Kimi 系列从早期长上下文产品、Kimi-VL、Kimi k1.5，到 Kimi K2、K2.5 和 K3 的技术路线。重点分析长上下文、MoE、MuonClip、KDA、Attention Residuals、原生视觉、Agent Swarm 和强化学习。

主线	代表模型
早期	Kimi Chat、长上下文对话、Kimi-VL
推理	Kimi k1.5：多模态 RL、长 CoT、128K RL context
开源 MoE	Kimi K2：1T/32B 激活、384 experts、MuonClip、Agentic RL
视觉 Agent	Kimi K2.5：15T 图文 token、原生多模态、Agent Swarm
KDA + AttnRes	Kimi K3：2.8T、1M context、896 experts、Kimi Delta Attention

一、Kimi 路线总览

Kimi 的发展主线可以概括为：先用超长上下文形成产品差异，再用多模态 RL 学习复杂推理，随后通过稀疏 MoE 把模型规模推向 1T 级，并把模型训练目标从“回答”转成代码、工具和 Agent 任务。K2.5 将视觉直接纳入底座并引入 Agent Swarm，K3 则进一步用 Kimi Delta Attention 和 Attention Residuals 处理百万 token 与超大模型深度。

阶段	模型	主要结构/能力	训练变化
长上下文	Kimi Chat / Kimi-VL	长上下文对话、图文理解、文档处理	多语言预训练、视觉语言对齐、长文本指令数据
推理 RL	Kimi k1.5	统一文本/视觉推理；short-CoT/long-CoT	128K RL context、partial rollout、在线策略优化、长度惩罚
MoE Agent	Kimi K2	1T 总参数、32B 激活、384 experts、128K	MuonClip 稳定预训练；代码/工具/Agent RL；自我生成任务
视觉 Agent	Kimi K2.5	原生视觉、多模态 token、Agent Swarm	15T 图文 token continued pretraining；并行 Agent RL
新架构	Kimi K3	2.8T、1M、KDA、AttnRes、896 experts/16 active	更高 scaling efficiency；长时程编码、视觉和研究 Agent

二、早期 Kimi 与 Kimi-VL

早期 Kimi

产品的核心竞争力是超长上下文：通过长文档、网页和多轮对话把模型从单轮问答扩展到文档级工作流。Kimi-VL 则将视觉编码器与语言模型连接，覆盖图像、文档、图表和视频理解。

这一阶段的架构重点通常不在改变 Transformer 主干，而在上下文窗口、位置编码、视觉 token 压缩和文档数据构造。训练上则从通用预训练扩展到长文档继续预训练、图文对齐、视觉指令微调和工具调用数据。

三、Kimi k1.5：把长上下文用于 RL 推理

Kimi k1.5 的核心结论是：RL 的 scaling 轴不只有模型参数和 rollout 数量，RL context length 本身也是重要维度。其 RL context 扩展到 128K，模型可以在一条长轨迹中进行规划、反思、修正和多步搜索。

机制	做法	作用
Partial Rollout	复用已有轨迹的大段上下文，只重新采样后续部分	减少长 CoT 从头生成的成本，提高 RL 样本效率
策略优化	改进 online mirror descent 类策略优化	在长轨迹和大更新幅度下保持训练稳定
奖励/采样	长度惩罚、有效采样策略、数据配方优化	平衡正确率、推理长度与答案质量
多模态	文本与视觉联合训练和 RL	同一推理框架处理数学图像、图表和视觉问题

Kimi k1.5 的特点是没有强依赖 MCTS、value function 或 process reward model，而是通过长上下文让模型在一条轨迹内产生更多搜索步骤。

四、Kimi K2：1T MoE 与 Agentic RL

Kimi K2 是 Kimi 从产品型闭源模型转向开放权重 MoE 的关键节点。公开资料给出约 1T 总参数、32B 激活参数、384 experts 和 128K context，采用 MuonClip 解决超大规模训练中的优化稳定性。

组件	设计	意义
MoE	384 experts；每 token 激活少量专家；约 1T 总参数/32B 激活	扩大知识和代码容量，控制每 token 计算
优化器	MuonClip	针对 Muon 的稳定性与大规模训练适配，改善收敛
Agent 训练	代码、终端、工具调用、环境执行和任务合成	从静态代码生成转向可执行软件工程任务
推理	Thinking/非 Thinking，长上下文和工具调用	在延迟与深度推理之间切换

五、Kimi K2.5：原生视觉与 Agent Swarm

Kimi K2.5 在 K2 基础上继续预训练约 15T 混合视觉和文本 token，成为原生多模态模型。视觉不再只是外接的问答接口，而是直接参与代码生成、视觉调试、工具选择和 Agent 执行。

Agent Swarm 是 K2.5 的训练与产品范式变化：模型可以自主拆解复杂任务、生成最多约 100 个专门子 Agent，并行执行最多约 1,500 次工具调用，再汇总结果。官方报告称并行化可将复杂任务端到端时间最多降低约 4.5 倍。

变化	K2 → K2.5	技术含义
数据	继续预训练约 15T 图文 token	视觉与文本能力共同提升，降低模态隔离
视觉编码	原生视觉输入；图像/视频到代码；视觉调试	把 screenshot、视频和生成结果纳入推理循环
Agent RL	Parallel-Agent RL；训练并行度逐步增加	学习任务分解、并行执行、结果合并和失败恢复
产品模式	Instant、Thinking、Agent、Agent Swarm	同一模型覆盖快速回答、深度思考和多 Agent workflow

六、Kimi K3：KDA、Attention Residuals 与百万上下文

Kimi K3 的公开技术博客给出 2.8T 参数、1M token context，并采用 Kimi Delta Attention（KDA）和 Attention Residuals（AttnRes）。MoE 规模进一步扩大到 896 experts，每 token 激活 16 个，并配合 Stable LatentMoE。

组件	K3 设计	相对 K2.5 的变化
KDA	Kimi Delta Attention：通过门控 delta 状态更新，让序列信息以更高效的递推方式传递	从标准全注意力/稀疏注意力进一步探索线性状态式长序列建模；降低百万上下文成本
AttnRes	Attention Residuals：跨层保留并聚合多层注意力信息	改善深层网络的信息流和跨层记忆，避免每层只依赖单一 residual 路径
MoE	896 experts, 16 active；Stable LatentMoE	更高稀疏度和总容量，进一步提升 scaling efficiency
原生视觉	视觉与文本共同输入，服务游戏、前端、CAD、研究和 GPU kernel 任务	视觉从理解模块变成 Agent 反馈回路的一部分

K3 的架构方向不是单纯增加专家数，而是同时处理三个瓶颈：KDA 处理超长序列，AttnRes 改善深层信息流，Stable LatentMoE 提升大规模稀疏模型的容量/计算比。

七、Kimi 训练演进总结

维度	K1.5	K2	K2.5	K3
主要目标	长 CoT 推理	代码/Agent	视觉 Agent/Swarm	长时程工程与研究 Agent
数据	文本+视觉 RL 数据	代码、工具和环境轨迹	15T 图文 token	更大规模多模态和 Agent 数据，完整配方待技术报告
架构	长上下文模型	1T/32B MoE + MuonClip	原生多模态 + K2 主干	2.8T MoE + KDA + AttnRes + 1M
RL	128K RL、partial rollout	Agent/代码 RL	并行 Agent RL、Swarm	长时程工具、视觉反馈和复杂工程任务

八、资料来源

Kimi k1.5: <https://arxiv.org/abs/2501.12599>

Kimi k1.5 官方仓库: <https://github.com/MoonshotAI/Kimi-k1.5>

Kimi K2 官方仓库: <https://github.com/MoonshotAI/Kimi-K2>

Kimi K2.5 Technical Report: <https://arxiv.org/abs/2602.02276>

Kimi K2.5 官方博客: <https://www.kimi.com/blog/kimi-k2-5>

Kimi K3 官方博客: <https://www.kimi.com/blog/kimi-k3>

Kimi K3 官方产品页: <https://www.kimi.com/en>

说明: Kimi K3 的完整技术报告和训练配方仍需以官方后续发布为准; 本报告对 K3 只总结官方博客已明确披露的架构和训练方向。