


下面重点介绍 **MiniMax M3 的模型架构 (Architecture)** 。我会按照你之前分析 DeepSeek-V4 / GLM-5 的方式，从 **整体结构** → **Attention** → **MSA稀疏机制** → **长上下文设计** → **多模态结构** 展开。

MiniMax M3 的核心定位是：

一个面向 Agent 场景的超长上下文 MoE Transformer，通过 MiniMax Sparse Attention (MSA) 替代 Full Attention，实现 1M token context，同时保持代码和 Agent 能力。

1. MiniMax M3 整体架构

M3 的整体可以理解为：



核心组件：

模块	作用
Transformer Backbone	基础语言模型
MoE FFN	扩大参数容量
MSA Attention	百万token上下文
Multimodal Encoder	图像/视频理解
Agent能力	工具调用、Computer Use

论文介绍 M3 的三个核心能力：


- 1. Coding
- 2. 1M Context
- 3. Native Multimodality

2. Backbone： 仍然是 Decoder-only Transformer

M3 本质仍然属于：

GPT-style Decoder Transformer

每层：



|
Residual

和 DeepSeek-V3 类似：

- Attention负责token交互
- MoE负责参数容量扩展

3. 最大创新：MSA (MiniMax Sparse Attention)

这是 M3 的核心架构创新。

论文指出：

Full Attention 的问题：

[$\text{Attention}(Q,K,V) = \text{softmax}(\frac{QK^T}{\sqrt{d}})V$]

复杂度：

[$O(L^2)$]

当：



`L=1,000,000 tokens`

时：

计算和显存不可接受。

因此 M3 提出：

MiniMax Sparse Attention

整体流程：





4. MSA 第一阶段：Indexer


MSA不是直接计算全部 Attention。

它先做：

Block-level retrieval

假设：


1M context:



Indexer计算：

哪些block重要。


流程：



例如：

1M token:

分成：




只选择：




后面真正Attention:

只计算:



5. MSA 第二阶段: Sparse Attention

选择之后:



复杂度:

从:

[$O(L^2)$]

变成:

[$O(L \times k)$]

其中：

$$k \ll L$$

所以：

百万context成为可能。

6. MSA 和 DSA / MoBA 的区别

这个非常值得和 GLM-5 比。

DeepSeek DSA


结构：



偏 token selection。

MoBA

结构：



|
Block routing

|
Attention

MiniMax MSA

特点：

论文强调：

MSA can partition KV into blocks more precisely, achieving higher effective context coverage.

区别：

	DSA	MoBA	MSA
选择单位	token	block	block
粒度	细	粗	更精细block
Indexer	✓	✓	✓
KV利用率	一般	较高	更高
目标	稀疏attention	长context	1M context

7. MSA Kernel设计：KV outer gather Q

这是 M3 非常工程化的一点。

普通 Attention：

```
for Q:

    load KV
```

```
compute attention
```

问题：

同一个KV block可能被重复读取。

MSA采用：

KV outer gather Q

即：

```
for KV block:

    load KV block once

    |

    find queries hitting this block

    |

    compute attention
```

图示：

```
传统：

Q1 -> KV1
Q2 -> KV1
Q3 -> KV1

KV1重复读取
```

MSA:

KV1

|
+----Q1

|
+----Q2

|
+----Q3

只读取一次

论文:

Each block is read only once and memory access is contiguous.

这个对于 GPU 非常重要。

因为:

Attention性能瓶颈通常不是FLOPs:

而是:



HBM bandwidth

KV cache movement

8. 为什么 MSA 对 GPU 更友好?


论文指出:

MSA:

arithmetic intensity is significantly better than common methods.

原因：

普通 sparse attention:



MSA:



所以：

官方宣称：

相比：

- Flash-Sparse-Attention
- Flash-MoBA

速度：

超过4倍。

9. 1M Context 下计算量变化

论文给出：

在1M context：

相比上一代模型：

```
per-token compute  
  
≈1/20
```

Prefill：

9× speedup

Decode：

15× speedup

原因：

主要来自：

```
Full Attention  
  
 $O(L^2)$   
  
↓
```

MSA

$O(L \cdot k)$

10. MoE 部分

虽然公开材料没有披露完整 expert 配置，但是从架构定位看：

M3仍然采用：



Sparse MoE Transformer

每个token：



Router



Top-k Experts



weighted sum

类似：

DeepSeek-V3:



256 experts

路线。

目的：

增加：

- coding能力
- agent能力

同时控制：

inference FLOPs。

11. 原生多模态结构

M3不是后接视觉模型。


论文强调：


M3 is a natively multimodal model.

训练：

从 Step 0 就加入多模态。


结构：






关键：

不是：




而是：



12. Interleaved Multimodal Training

M3采用：



Text
Image
Text

交错数据。

例如：

一个网页：

标题

图片

解释

代码

截图


描述

整体进入模型。

论文认为：

interleaved data 比纯 synthetic data 更容易扩展。

13. M3 架构总结图





14. 和 DeepSeek-V4 / GLM-5 对比

	DeepSeek-V4	GLM-5	MiniMax M3
Attention	MLA+Sparse	MLA+DSA	MSA
稀疏单位	token	token	KV block
长上下文	128K/更高	200K	1M
KV优化	latent KV	latent KV	sparse KV
kernel优化	Flash MLA	DSA kernel	KV outer gather Q

	DeepSeek-V4	GLM-5	MiniMax M3
重点	推理效率	Agent reasoning	超长Agent

核心总结一句话

MiniMax M3 的本质是一个 MoE Decoder Transformer, 通过 MSA 将 Attention 从 “所有 token 两两交互” 变成 “KV block 检索 + 稀疏计算”, 再结合 KV outer gather Q 的 GPU kernel 设计, 实现 1M context, 并为长期 Agent 编程任务提供低成本长记忆能力。