

Qwen 系列模型发展历程

LLM · 多模态 · 全模态：架构、训练与技术路线演进

本报告梳理 Qwen 从 2023 年首代模型到 2026 年 Qwen3.6 公开信息的演进，覆盖文本 LLM、视觉/音频多模态和全模态模型。重点区分模型发布、架构变化、数据变化与后训练变化；细节未公开处明确标注。

主线	覆盖内容
LLM	Qwen、Qwen1.5、Qwen2、Qwen2.5、Qwen3、Qwen3.6，以及 Math、Coder、QwQ 分支
多模态	Qwen-VL、Qwen2-VL、Qwen2.5-VL、Qwen3-VL、Qwen-Audio
全模态	Qwen2.5-Omni、Qwen3-Omni：文字、图像、视频、音频输入与文本/语音输出

一、全局路线：三次范式跃迁

Qwen 不是单纯放大参数，而是经历了三次跃迁：建立强语言底座；扩展到视觉、音频、文档和工具智能体；把多模态放入统一的时序建模与生成框架，并进一步引入稀疏 MoE、混合注意力和可控推理。

阶段	代表模型	核心变化	训练关键词
语言底座	Qwen / 1.5 / 2	Decoder-only Transformer、GQA、长上下文、早期 MoE	预训练 + SFT/RLHF
专家化与推理	2.5 / Math / Coder / QwQ / 3	数据工程、合成数据、思考/非思考统一、蒸馏与 RL	7T→18T→36T token；工具调用
多模态与全模态	VL / Audio / Omni / 3.6	动态分辨率、视频时间建模、Thinker-Talker、混合架构	模态对齐、端到端流式训练

判断标准：只有当骨干架构、输入输出形式、训练范式或能力目标发生实质变化时，才把它视为路线演进；量化版、部署版和同一基座的不同对齐版不单列为新一代。

二、LLM 主线：版本、架构与训练

版本	架构	训练与数据	变化
Qwen（2023）	Decoder-only Transformer；多尺寸 dense	最高约 3T token 多语言预训练；Chat 采用 SFT 与 RLHF	建立中文/英文通用语言底座，覆盖生成、代码和工具
Qwen1.5（2024）	延续 dense；大模型开始采用 GQA	更高质量预训练数据；对话 SFT 与偏好对齐增强	效率、对话质量和开源生态成熟化
Qwen2（2024）	全尺寸 GQA；0.5B–72B dense，另有 57B-A14B MoE；小模型可 tied embedding	约 30 种语言；预训练后 instruction tuning；YARN 长上下文	128K 上下文；代码、数学、多语言增强
Qwen2.5（2024）	总体延续 Qwen2 骨干，形成通用、Math、Coder 分支	高质量预训练数据 7T→18T；合成数学/代码；更强 SFT/RL	从通用基座走向模型家族与专家化
QwQ / 2.5-Math	主要创新在推理策略与后训练	RM 采样、迭代 SFT、最终 RL；CoT 与 TIR；可验证奖励	把长思考经验带回通用模型
Qwen3（2025）	dense + MoE；统一 thinking/non-thinking；thinking budget	约 36T token、119 语言/方言；利用 VL、Math、Coder 生成和清洗数据；蒸馏与 RL	快速回答与深度推理统一进同一模型
Qwen3.6（2026）	公开仓库信息：Gated Delta Networks + 稀疏 MoE；early-fusion 多模态方向	完整数据规模与阶段配方待正式报告；公开方向指向万亿级多模态 token	从标准注意力走向门控状态与稀疏专家结合

三、LLM 架构变化的含义

- 1) GQA: Qwen2 把 GQA 扩展到所有尺寸，多个 query head 共享较少的 key/value head，降低 KV cache 容量与访存压力。它是推理结构变化，不是单纯量化。
- 2) Dense→MoE: Qwen2 的 57B-A14B 是早期稀疏专家尝试；Qwen3 将 dense 与 MoE 并列为主力。路由器让每个 token 只激活少量专家，以更低每 token FLOPs 获得更大的总参数容量。
- 3) 模型切换→模式切换: Qwen3 的 thinking/non-thinking 通过同一模型、模板和预算控制，适配低延迟问答与多步数学/代码任务。
- 4) 混合架构: Qwen3.6 公开信息显示 Gated Delta Networks 与稀疏 MoE 结合，目标是用线性递推/门控状态处理长序列，用稀疏专家保留高容量非线性变换。

训练流程共性

阶段	目标	典型做法
预训练	通用语言 and 知识	多语言网页、文档、书籍、代码、数学；去重、过滤、配比和合成数据
能力增强	补齐代码、数学、长文档、Agent	领域继续预训练；模型生成数据；执行代码与工具环境
监督微调	指令遵循和输出格式	对话、CoT、工具调用、结构化输出、安全数据
偏好/RL	质量、可靠性和推理	RLHF/RM、可验证奖励、结果筛选、迭代 SFT/RL

四、多模态：从视觉外挂到统一感知

模型	架构	训练重点	能力
Qwen-VL（2023）	Qwen-LM + visual receptor + 视觉语言接口	三阶段视觉语言预训练/指令微调/对齐；多语言清洗语料	图像理解、OCR、定位、中文对话
Qwen2-VL（2024）	Naive Dynamic Resolution；图像 token 数随分辨率变化；统一图像/视频	视觉预训练、多阶段指令数据、视频时序	文档、图表、视频和任意尺寸图像
Qwen2.5-VL（2025）	原生动态分辨率 ViT；Window Attention；absolute time encoding	空间定位、结构化抽取、长视频、视觉 Agent 数据	框/点定位、票据表格、小时级视频、电脑/手机操作
Qwen3-VL（2025）	以 Qwen3 为语言基础，强化视觉编码、空间/视频动态和 Agent	视觉推理、长上下文、工具交互；延续 thinking 路线	视觉理解、代码、推理、Agent 融合
Qwen-Audio（2024）	音频编码器连接语言模型	多任务音频指令和跨语言语音数据	语音识别、理解与指令跟随

视觉路线：固定视觉 token → 动态分辨率 → 原生高分辨率 ViT + 窗口注意力 → 视觉推理、视频时间理解和 Agent 行为。核心收益是减少统一缩放造成的信息损失。

五、全模态：Qwen2.5-Omni 与 Qwen3-Omni

全模态不只是增加音频编码器，而是同时解决多模态时间关系、文本与语音联合输出和流式低延迟。

Qwen2.5-Omni 的 Thinker-Talker

- Thinker 融合文字、图像、视频和音频，负责语义理解与文本生成。
- Talker 读取 Thinker 隐藏表示，以双轨自回归结构生成音频 token。
- TMRoPE 将视频时间戳与音频时间轴统一。
- 音频和视觉编码器 block-wise 处理；滑窗 DiT 限制语音解码感受野，降低首包延迟。

Qwen3-Omni 的方向

- MoE-based Thinker-Talker：扩大总容量、限制每 token 激活计算。
- AuT 预训练方向：强化音频通用表示。
- 多 codebook 音频 token：在质量、并行度和延迟之间折中。
- 文字、图像、音频、视频输入，文本与自然语音流式输出。

训练关键：模态编码器适配、跨模态对齐、指令微调、语音生成和端到端联合优化共同构成训练链条；公开报告没有披露所有数据规模与完整配方。

六、专用分支如何反哺主干

分支	目标	关键训练	反哺主干
Qwen2.5-Math	数学推理	RM 采样、数据迭代、SFT 迭代、最终 RL；推理时 RM 引导采样	可验证奖励、自我改进、TIR
Qwen2.5/3-Coder	代码与仓库 Agent	代码继续预训练、执行反馈、工具环境、任务合成与 RL	代码、工具和 Agent 能力
QwQ	长思考	推理轨迹、结果筛选、偏好/可验证奖励、推理预算	推动 Qwen3 thinking 统一
Qwen-Image	图像生成/文字渲染	图文收集、过滤、标注、合成、平衡；扩散/DiT 类训练	拓展视觉生成生态，不同于 LLM 骨干

可以把 Qwen 家族理解为“主干模型 + 专家数据工厂”：Math、Coder、VL 模型不仅是产品分支，也在为下一代通用模型生产更高质量的数学、代码、文档和多模态数据。

七、训练演进与路线判断

数据：从更多网页到高质量、可验证、可交互的数据。Qwen2.5 将高质量预训练规模从 7T 扩至 18T；Qwen3 进一步到约 36T，并显式利用 VL、Math、Coder 模型生成和清洗数据。

后训练：从传统 SFT/RLHF 到多轮自我改进。数学分支形成“模型生成候选—奖励模型筛选—SFT 迭代—再训练 RM—RL”的闭环。

推理：从固定输出策略到可控计算。Qwen3 用 thinking/non-thinking 和 thinking budget 让计算量随任务难度变化；Qwen3.6 则从骨干结构层面降低长上下文成本。

模态：从外挂适配器到端到端统一。VL 先增加视觉 receptor，再解决动态分辨率和视频时间；Omni 进一步要求 Thinker、Talker、时间编码和流式解码共同优化。

八、时间线

时间	模型/分支	意义
2023	Qwen / Qwen-VL	语言底座与视觉语言起点
2024 上半年	Qwen1.5 / Qwen2	GQA、128K、早期 MoE、开源生态成熟
2024 下半年	Qwen2.5 / Math / Coder / QwQ / Qwen2-VL	7T→18T；专家化、推理和动态分辨率
2025	Qwen2.5-VL / Omni / Qwen3 / Qwen3-VL / Qwen3-Omni	36T、119 语言；思考统一；视觉与全模态流式交互
2026	Qwen3.6 公开方向	Gated Delta Networks + 稀疏 MoE；early-fusion 多模态方向

九、资料来源

以下优先使用论文、官方博客和官方仓库：

Qwen Technical Report: <https://arxiv.org/abs/2309.16609>

Qwen-VL: <https://arxiv.org/abs/2308.12966>

Qwen2 Technical Report: <https://arxiv.org/abs/2407.10671>

Qwen2 官方说明: <https://qwenlm.github.io/blog/qwen2/>

Qwen2-VL: <https://arxiv.org/abs/2409.12191>

Qwen2.5: <https://arxiv.org/abs/2412.15115>

Qwen2.5-Math: <https://arxiv.org/abs/2409.12122>

Qwen2.5-VL: <https://arxiv.org/abs/2502.13923>

Qwen2.5-Omni: <https://arxiv.org/abs/2503.20215>

Qwen3: <https://arxiv.org/abs/2505.09388>

Qwen3 官方仓库: <https://github.com/QwenLM/Qwen3>

Qwen3-VL: <https://github.com/QwenLM/Qwen3-VL>

Qwen3-Omni: <https://github.com/QwenLM/Qwen3-Omni>

Qwen3.6: <https://github.com/QwenLM/Qwen3.6>

Qwen-Image: <https://arxiv.org/abs/2508.02324>

说明：Qwen3.6 的完整训练数据规模、阶段配方和最终多模态结构以官方正式技术报告为准；本报告只总结公开仓库明确表达的架构方向，不对未披露细节作推测。